PROJET • EDA

ANALYSE EXPLORATOIRE DES DONNÉES DE VENTES

EDA avec Python

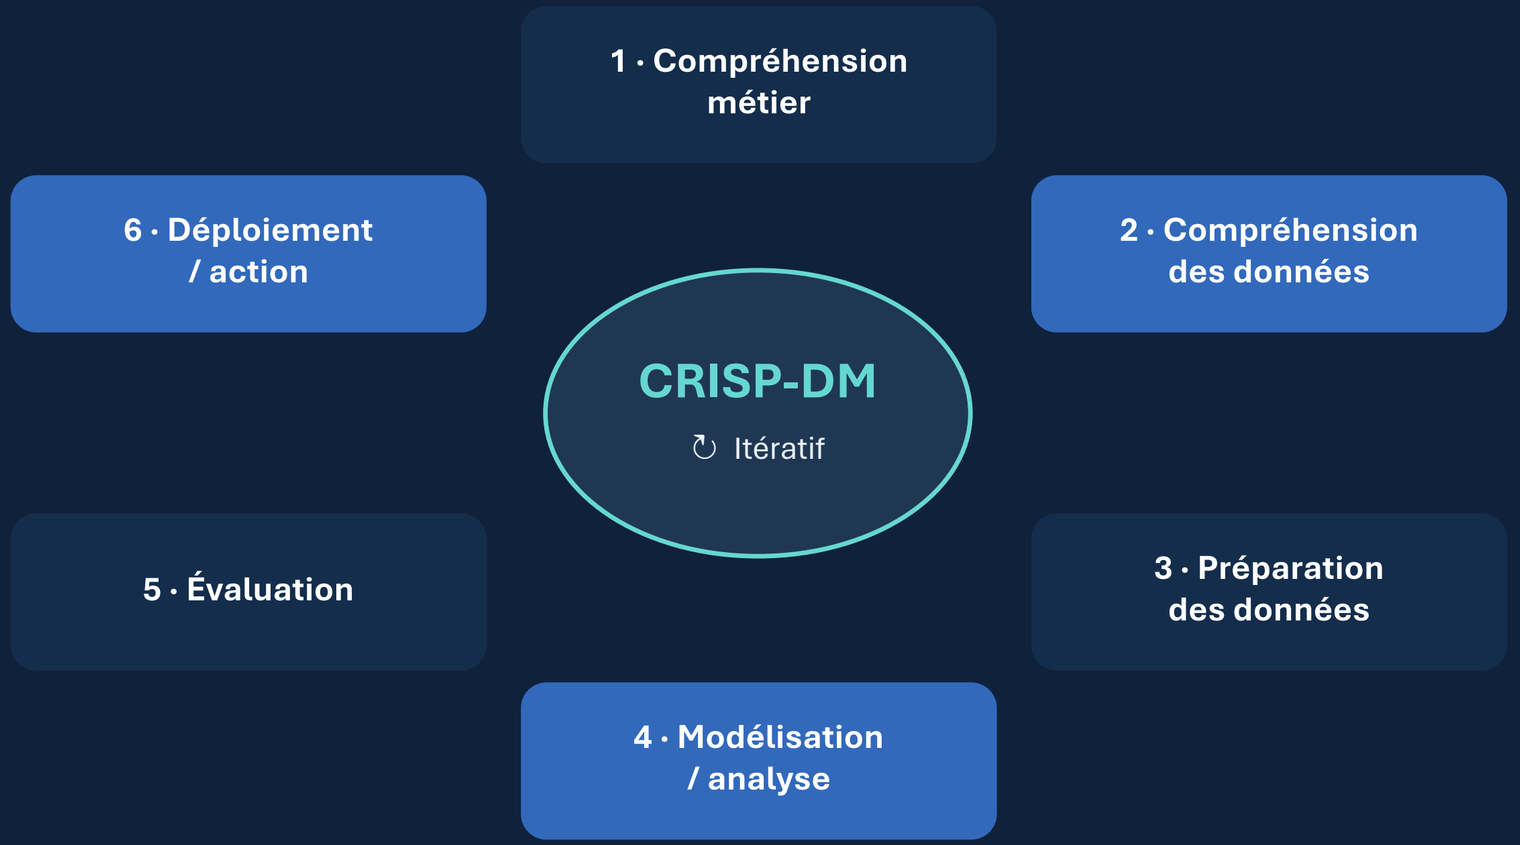
Du contrôle des données aux décisions métier, puis aux choix techniques Big Data



Nessim Hjaiej • Manar Ben Salem • Yosr Rawane

IHEC Carthage | M1 Big Data Analytics | Année universitaire 2026–2027

CRISP-DM : les six phases



Un résultat incohérent peut nous ramener aux données ou à leur préparation.

Comment CRISP-DM structure notre TP ?

Partie 1 · Compréhension métier

Définir la question métier et les critères de succès ; charger les CSV et construire le dictionnaire de données.

Partie 2 · Compréhension des données

Diagnostiquer la qualité : valeurs manquantes, doublons, formats et cohérence métier.

Partie 3 · Préparation des données

Renommer les colonnes ; créer Cost, Revenue, Final_Revenue, Zone et Direction.

Parties 4–7 · Modélisation / analyse

Statistiques et graphiques, filtres, groupby, jointures et contrôle de l’intégrité.

Partie 8 · Évaluation

Comparer régions, paiements et promotions ; mesurer la fiabilité et les limites ; formuler des recommandations à tester.

Parties 9–10 · Déploiement, 2e itération

Vectorisation, mémoire et passage à l’échelle ; Partie 10 : prévision exploratoire (modèles de référence, MAE, RMSE).

Contexte et problématique

sales.csv

Transactions : quantités, prix, régions, canaux, paiements, remises et promotions.

products.csv

Référentiel produit : ProductID, nom et catégorie ; enrichissement et contrôle des références.

QUESTION MÉTIER

Comment transformer des ventes imparfaites en décisions mesurables ?

Deux sources complémentaires

816

lignes initiales de sales.csv

10

produits dans products.csv

ProductID

clé de jointure

Familles de variables

OrderID, CustomerID, StoreID ;
Date, Region, Channel et PaymentType ;
Units, UnitPrice, Discount, PromoFlag.

Référentiel

ProductID, ProductName et Category : enrichir les ventes sans perdre les transactions.

Qualité : diagnostiquer avant de traiter

89

Channel manquants

57

PaymentType manquants

126

OrderTime manquants

Catégories

Modalité « Inconnu » pour Channel et PaymentType ;
ne jamais assimiler absence et zéro.

Heures et types

Conserver OrderTime absent ;
vérifier les formats de Date, Units, Discount et PromoFlag.

Imputation par 0 : une moyenne illustrative passe de 28,19 à 25,33 dans le rapport.

Nettoyage et intégrité : 800 ventes

816
ventes initiales

−16
doublons exacts

800
ventes conservées

Références manquantes

88 ventes utilisent ProductID 210, absent du catalogue de produits.

Choix : conserver

Ces ventes sont réelles dans la table de transactions ; les exclure créerait un biais.

Un OrderID répété ne suffit pas à établir un doublon exact.

Trois indicateurs, trois sens différents

Cost

UnitPrice × Units
Montant BRUT ; ce n'est PAS le coût d'achat.

Revenue

UnitPrice × Units × (1 − Discount)
Montant après remise.

Final_Revenue

Revenue × 0,95 si PromoFlag=True ; sinon Revenue.

≈ 200 468

Revenue total du rapport

≈ 197 832

Final_Revenue total du rapport

Exploration : dispersion et prudence

≈ 250,6

Revenue moyen

≈ 206,8

Revenue médian

≈ 896

Revenue maximum

Asymétrie et extrêmes

Skewness ≈ 0,90 ;
9 valeurs au-delà de 764,4 selon IQR ;
4 selon score z.

Corrélations

Revenue–Final_Revenue : 0,999 / Ce qui est logique car l'un dérive de l'autre
Units–Cost : 0,72 ;
corrélation ≠ causalité.

Les 10 % des transactions les plus élevées génèrent 25,8 % du Revenue.

Filtres, agrégations et jointures

Filtrer

Masques booléens, loc[] et query() : cibler les transactions.

Agréger

groupby : sommes, moyennes, effectifs par région et paiement.

Joindre

left join + indicator : repérer les références manquantes.

712

lignes appariées

88

lignes non appariées

La jointure gauche préserve 800 ventes ; une inner join n’en garde que 712.

Partie 8 · Des résultats aux décisions

Observer

Comparer les régions, modes de paiement et promotions.

→

Interpréter

Identifier ce que les chiffres suggèrent réellement.

→

Décider

Proposer des actions mesurables, à tester.

Chaque règle doit être accompagnée d’une hypothèse et d’un indicateur.

Centre East : premier Revenue régional



41 471

Revenue Centre East

20,7 %

part annoncée du total

Vérification : la somme des 6 valeurs affichées (201 284) diffère du total rapporté (≈ 200 468) ; écart à réconcilier.

Le total ne raconte pas toute l’histoire

144

transactions Centre East

1 532

unités Centre East

≈ 288

Revenue / transaction

Observation

Centre East est à la fois active en volume et au-dessus de la moyenne globale ≈ 250,6.

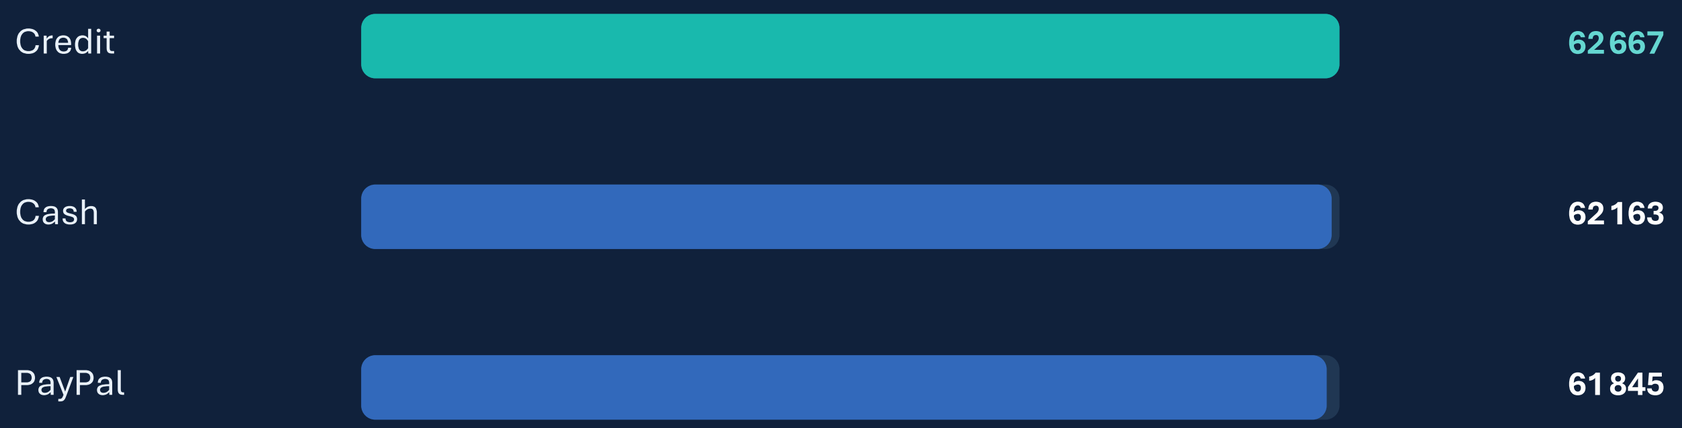
Interprétation prudente

Comparer quantité vendue, nombre de ventes et panier moyen ; éviter de supposer une cause.

North West : 110 transactions, mais ≈ 271 de Revenue moyen.

il faut croiser le total avec des indicateurs unitaires avant de conclure à une sous-performance.

Modes de paiement : différences limitées



13 793

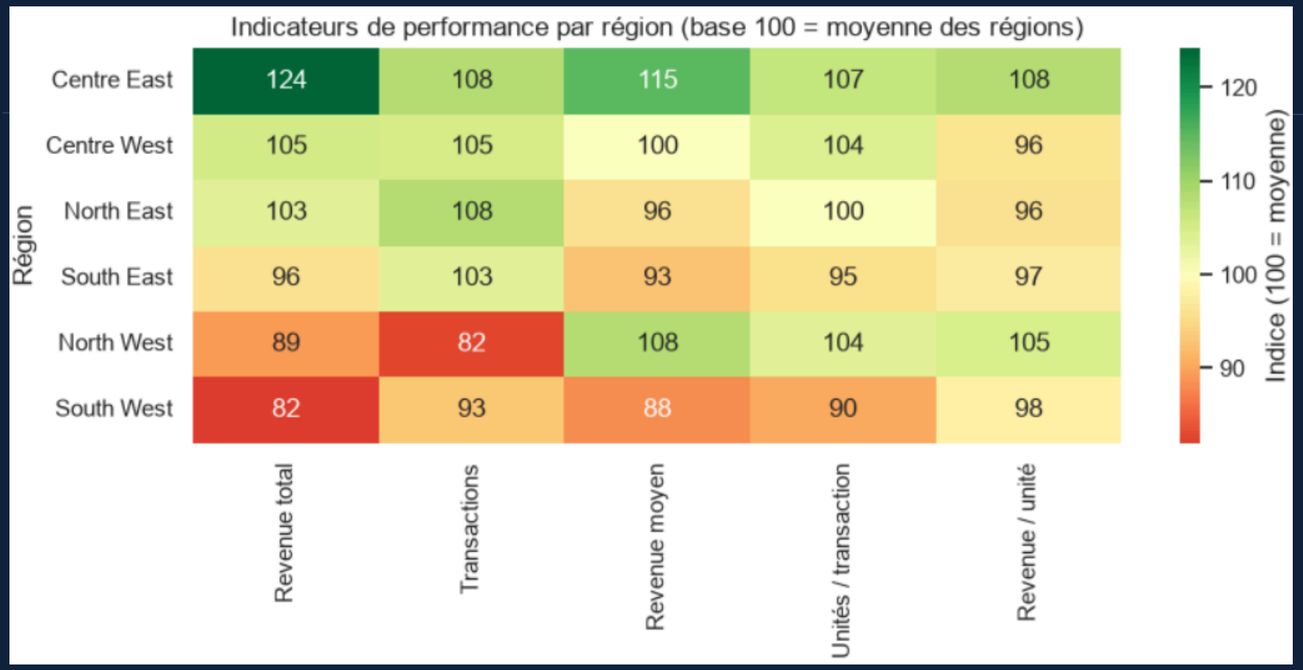
Revenue non renseigné

57

paiements inconnus

Cash : revenu moyen ≈ 265,7 ; aucune relation causale démontrée avec le mode de paiement.
les 57 ventes « Inconnu » représentent 13 793 de Revenue → leur attribution réelle pourrait changer le classement.

South West : un segment à surveiller



27 392

Revenue régional

9 vs 10

unités / vente : local vs global

221 vs 251

Revenue moyen : local vs global

Observation

Plus faible Revenue parmi les six régions.

→

Hypothèse

Volume / quantités peuvent contribuer à l'écart.

→

À confirmer

Étudier villes, périodes, trafic, concurrence.

Promotions : aucun effet causal établi

212

transactions en promotion

248,7

Revenue moyen avec promo

251,3

Revenue moyen sans promo

Observation

26,5 % des ventes portent PromoFlag ; 9,92 unités vs 10,03 hors promo.

Méthode recommandée

Test A/B randomisé : comparer incrément de Revenue et marge si les coûts sont connus.

Comparer deux groupes observés ne permet pas d’attribuer une différence à la promotion.
Une observation ne permet pas de tirer des conclusions.

Recommandation 1 · Panier moyen

Observation

South West : 9 unités et Revenue moyen 221.

→

Interprétation

Hypothèse d’un panier moins volumineux.

→

Action

Tester lots, ventes additionnelles et seuil de livraison.

→

Indicateur

Unités/commande, panier moyen, marge réelle.

Pilote ciblé sur South West ; ne généraliser qu’après évaluation.

Recommandation 2 · Promotions testées

Constat

248,7 avec promo vs 251,3 sans.

→

Test

A/B par région ou catégorie ; groupes comparables.

→

Mesure

Revenue incrémental, conversion, unités, marge.

→

Décision

Conserver, modifier ou arrêter selon le test.

Collecter dates de campagne, définition PromoFlag, coûts de remise et données de marge.

Recommandation 3 · Qualité des données

88

ventes ProductID 210

23 523

Revenue concerné

89 / 57

Channel / PaymentType inconnus

Contrôler

Vérifier ProductID à la saisie.

→

Corriger

Compléter le référentiel produit.

→

Suivre

Taux de correspondance et complétude.

Limites : ce que les données ne prouvent pas

Marge commerciale

Cost = UnitPrice × Units, pas coût d’achat. Livraison, commissions, retours et TVA manquent.

Causes des écarts

Pas de démonstration que région, paiement ou promotion causent la performance.

Qualité des données

88 ventes sans produit reconnu, paiements et canaux incomplets.

Cohérence interne

Total des six régions différent du Revenue total affiché : rapprochement requis.

Partie 9 · Efficacité technique

Temps

Réduire les passages Python inutiles.

→

Mémoire

Adapter les types sans perdre de précision.

→

Échelle

Choisir la complexité proportionnée au volume.

Objectif : traitement fiable et maintenable, pas technologie distribuée à tout prix.

Vectorisation vs itertuples() vs iterrows()

Méthode	Principe	Compromis
Vectorisation	Opérations colonne par colonne	Plus rapide dans le TP
itertuples()	Parcours de tuples ligne à ligne	Moins de surcharge que iterrows()
iterrows()	Series créée pour chaque ligne	Surcoût Python important

Sur 200 000 lignes : quelques ms en vectorisé, 0,1 à 0,6 s avec itertuples(), 5 à 20 s avec iterrows() (les temps varient selon l'exécution).

BONNE PRATIQUE EDA

Toujours privilégier les opérations pandas/NumPy vectorisées : elles réduisent la charge CPU et la latence.

Pourquoi privilégier la vectorisation ?

Boucle Python

Chaque ligne requiert des accès individuels et une interprétation répétée.

Opérations Pandas / NumPy

Les calculs sur colonnes utilisent des routines optimisées, avec moins de surcharge.

```
df["Revenue"] = df["UnitPrice"] * df["Units"] * (1 - df["Discount"])
```

Avantage habituel : code plus concis, testable et maintenable ; aucun benchmark fictif.

Optimiser la mémoire sans altérer les résultats

category

Utile pour Region, PaymentType et autres colonnes à faible cardinalité.

Entiers adaptés

Choisir int8, int16, etc. uniquement si la plage des valeurs le permet.

float32 / float64

float32 consomme moins, mais peut réduire la précision des montants.

Décision : optimiser après avoir vérifié les plages de valeurs et comparé les résultats. Pour des calculs comptables, privilégier une précision adaptée.

Quel outil selon la taille du problème ?

Solution	Point fort	Limite / condition
Pandas	Simple ; en mémoire ; 800 ventes	RAM d’une seule machine
Pandas + chunksize	Lots lus et agrégés progressivement	Consolidation inter-lots nécessaire
Dask	Partitionnement et parallélisme	Ordonnancement et shuffle coûteux
PySpark	Calcul distribué sur cluster	Infrastructure et complexité

Pour les 800 ventes du TP : Pandas reste le choix le plus proportionné.

Quand Pandas ne suffit-il plus ?

Pandas + chunksize

Lire et traiter les données par blocs lorsque les opérations peuvent être agrégées progressivement.

Dask

Paralléliser des opérations et travailler sur des données plus grandes que la mémoire d’une machine.

PySpark

Traitement distribué sur un cluster pour de très grands volumes et des pipelines distribués.

Pour les 800 ventes conservées dans le TP, Pandas est suffisant. Le choix d’un outil distribué dépend du volume, de la mémoire, du temps attendu et de l’infrastructure.

• Tous les calculs ne se distribuent pas de la même façon

Plus faciles à distribuer

- Calculs ligne par ligne
- Filtres et sélections
- Sommes et comptages
- Moyennes via somme + nombre

À traiter avec attention

- Jointures et échanges entre machines
- Détection globale des doublons
- Médianes, quantiles et tests
- Références manquantes / données déséquilibrées

Un traitement distribué ne consiste pas seulement à lancer le même code sur plusieurs machines : il faut vérifier la logique globale et la cohérence des résultats.

Déploiement · Continuer le cycle CRISP-DM

Corriger

Référentiel et contrôles à l’entrée.

→

Piloter

Dashboard régions, qualité et panier moyen.

→

Tester

A/B promotions et actions South West.

→

Réévaluer

Mesurer, apprendre et relancer CRISP-DM.

MERCI

Questions et discussion