معهد الدراسات العليا التجارية بقرطاج
IHEC Carthage

2026 — 2027

Rapport TP EDA

EDA et interrogation des données avec Python

Étudiants : Nessim Hjalej - Manar ben salem - Yosr Rawane

Matière : Python pour la Data Science

Formation : Master 1 — Big Data Analytics & E commerce

Professeurs:
Madame Dhouha Attia
Madame Jihène Tounsi

Année universitaire 2026/2027

Table des matières

Partie 1 — Chargement et exploration initiale (Q1–Q5) 4

Partie 2 — Qualité et préparation des données (Q6–Q12) 10

Partie 3 — Transformation et création de variables (Q13–Q19) 18

Partie 4 — Statistiques descriptives et exploration graphique (Q20–Q26) 26

Partie 5 — Interrogations et filtrage avec Pandas (Q27–Q31) 34

Partie 6 — Agrégations et analyse par segments (Q32–Q37) 40

Partie 7 — Jointures et contrôle de l'intégrité (Q38–Q42) 47

Partie 8 — Analyse métier et recommandations (Q43–Q48) 53

Partie 9 — Efficacité et ouverture Big Data (Q49–Q52) 60

Conclusion 65

01

Chargement et exploration initiale

Questions couvertes : Q1–Q5

Q1

sales — 5 premières lignes

	index	OrderID	Date	OrderTime	Region	ville	StoreID	Channel	customer	Producti
0	206	1001	1.743120e+18	15:08:00	South West	Kebili	10	Retail	508	2(
1	731	1002	1.762730e+18	51:52.8	Centre East	Monastir	11	Online	506	2(
2	268	1003	1.750460e+18	19:43:24	Centre East	Mahdia	15	Online	502	2(
3	748	1004	1.745970e+18	NaN	Centre West	Kasserine	15	Online	506	2(
4	449	1005	1.743720e+18	41:04.8	Centre East	Sousse	11	Online	501	2(

sales — 5 dernières lignes

	index	OrderID	Date	OrderTime	Region	ville	StoreID	Channel	customer	Produ
811	795	1778	1.713050e+18	NaN	South East	Medenine	11	Retail	506	
812	627	1501	1.733180e+18	15:15:24	North East	Tunis	13	Retail	506	
813	21	1006	1.725750e+18	13:33.6	North East	Manouba	15	Retail	507	
814	640	1724	1.734310e+18	00:07.2	South East	Sfax	14	NaN	506	
815	652	1666	1.722120e+18	24:04.8	Centre West	Kasserine	10	Online	503	

products — 5 premières lignes

	ProductID	ProductName	Category
0	205	E-book	Digital Products
1	203	iphone	Electronics
2	209	cleaning products	Household
3	206	Online course	Digital Products
4	202	Computer	Electronics

products — 5 dernières lignes

	ProductID	ProductName	Category
5	207	Handbag	Accessories
6	204	blender	Electronics
7	201	toothpaste	Personal Care
8	200	Shampoo	Personal Care
9	208	watch	Accessories

Interprétation

chargement avec pd.readcsv et affichage des premiers lignes avec head , tail pour les dernières lignes. Exploration initiale nécessaire pour connaître le type des données.

Décision / Justification

Q2

```
===== sales =====
Dimension : (816, 15)
Colonnes  : ['index', 'OrderID', 'Date', 'OrderTime', 'Re
index            int64
OrderID          int64
Date           float64
OrderTime       object
Region          object
ville           object
StoreID          int64
Channel         object
customer         int64
ProductID        int64
Units            int64
UnitPrice      float64
disc           float64
prom              bool
PaymentType     object
Mémoire   : 275.9 Ko

===== products =====
Dimension : (10, 3)
Colonnes  : ['ProductID', 'ProductName', 'Category']
ProductID       int64
ProductName    object
...
```

```
Transactions (lignes de sales) : 816 | OrderID distincts : 800
Produits dans le référentiel   : 10 | ProductID distincts dans sales : 7
```

Interprétation

Exploration des noms de colonnes et des types pour des modifications éventuelles .
le nombre de transactions est différent de nombre de order ID qui est la clé primaire .
Un nétoyage est nécessaire pour la clé primaire

Q3

Generate + Code + Markdown | Run All | Clear All Outputs | Outline ... Select Kernel

	Variable	Type observé	Signification supposée	Rôle dans l'analyse	À confirmer
0	index	int64	Numéro de ligne / index technique issu de l'ex...	Technique (à écarter)	Oui
1	OrderID	int64	Identifiant de la commande	Clé de transaction, contrôle des doublons	Non
2	Date	float64	Date de la commande, stockée en timestamp numé...	Analyse temporelle	Oui (unité ns supposée)
3	OrderTime	object	Heure de la commande, formats mélangés	Analyse horaire (limitée)	Oui (format)
4	Region	object	Région (Zone + Direction)	Segmentation géographique	Non
5	ville	object	Ville de la vente	Segmentation géographique fine	Non
6	StoreID	int64	Identifiant du magasin	Segmentation (identifiant, non numérique)	Oui (lien avec ville)
7	Channel	object	Canal de vente (Online / Retail)	Segmentation par canal	Non
8	customer	int64	Identifiant client	Segmentation client (identifiant)	Non
9	ProductID	int64	Identifiant produit	Clé de jointure vers products	Non
10	Units	int64	Quantité vendue	Variable numérique de volume	Non
11	UnitPrice	float64	Prix unitaire	Variable numérique de prix	Oui (devise)
12	disc	float64	Remise appliquée	Variable numérique (fraction)	Oui (fraction vs %)
13	prom	bool	Indicateur de promotion	Variable booléenne	Oui (relation avec disc)
14	PaymentType	object	Mode de paiement	Segmentation par paiement	Non

Interprétation

Table importante lors du travail en équipe .
Sert à être une table de référence pour des modifications de type éventuelles.

Décision / Justification

Q4

```python
print('Type :', sales_raw.Date.dtype)
print(sales_raw.Date.head().to_list())
print(sales_raw.Date.describe())

try:
    pd.to_datetime(sales_raw.Date, unit='s')
except Exception as e:
    print('\nunit=s impossible :', type(e).__name__)

date_conv = pd.to_datetime(sales_raw.Date, unit='ns')
print('\nunit=ns -> min :', date_conv.min(), '| max :', date_conv.max())
print('Valeurs distinctes de Date :', sales_raw.Date.nunique(), 'sur', len(sales_raw))
```

[5] Python

```
Type : float64
[1.74312e+18, 1.76273e+18, 1.75046e+18, 1.74597e+18, 1.74372e+18]
count    8.160000e+02
mean     1.737517e+18
std      1.598274e+16
min      1.709340e+18
25%      1.724460e+18
50%      1.737895e+18
75%      1.750400e+18
max      1.765320e+18
Name: Date, dtype: float64

unit=s impossible : OutOfBoundsDatetime

unit=ns -> min : 2024-03-02 00:40:00 | max : 2025-12-09 22:40:00
Valeurs distinctes de Date : 448 sur 816
```

Interprétation

Date est type float → elle nécessite un typeCast pour être lisible .
Date peut aller jusqu'au nano sacondes , non nécessaire pour notre cas d'utilisation .

Q5

Interprétation

Les premières lignes ne sont qu'un petit échantillon : elles cachent les problèmes qui apparaissent plus loin. Il faut donc vérifier :

1. Valeurs manquantes : combien en manque-t-il par colonne ? (isna().sum())
2. Doublons : des lignes répétées ? Les identifiants sont-ils bien uniques ? (duplicated(), OrderID.is_unique)
3. Types et formats : chaque colonne a-t-elle le bon type, et les dates et heures sont-elles écrites de la même façon ? (dtypes, info())
4. Valeurs extrêmes : des chiffres aberrants, négatifs ou nuls ? (describe())
5. Catégories et liens entre tables : les valeurs prévues sont-elles les seules présentes (value_counts()), et chaque ProductID existe-t-il bien dans le référentiel ?

02

Qualité et préparation des données

Questions couvertes : Q6–Q12

Q6

```
sales
```

	manquantes	pourcentage
OrderTime	128	15.69
Channel	90	11.03
PaymentType	59	7.23
Date	0	0.00
Region	0	0.00
OrderID	0	0.00
index	0	0.00
StoreID	0	0.00
ville	0	0.00
ProductID	0	0.00
customer	0	0.00
Units	0	0.00
UnitPrice	0	0.00
disc	0	0.00
prom	0	0.00

```
products
```

	manquantes	pourcentage
ProductID	0	0.0
ProductName	0	0.0
Category	0	0.0

Interprétation

Seulement trois colonnes dans la table sales qui contiennet des valuers manquantes .
les pourcentages sont entre 7% à 15% , on ne peut pas tout simplement enlever les lignes concernés . on peut penser à l'imputation simple ou avancé (machine learning)

Q7

	Colonne	Stratégie	Justification
0	OrderTime	Conservation (NaN)	Aucune valeur plausible à inventer ; colonne d...
1	Channel	Modalité « Inconnu »	Variable catégorielle : on conserve les lignes...
2	PaymentType	Modalité « Inconnu »	Même logique ; les lignes restent comptées dan...

```
Aucune variable numérique de sales ne contient de valeur manquante.
Simulation sur UnitPrice : 10 % de valeurs masquées aléatoirement, puis imputation.
```

	Original	Masqué (10 % NaN)	Imputé médiane	Imputé 0
count	816.00	734.00	816.00	816.00
mean	28.19	28.16	28.19	25.33
median	28.56	28.41	28.41	25.58
std	12.74	12.84	12.18	14.83
min	5.16	5.16	5.16	0.00
max	49.93	49.93	49.93	49.93

Interprétation

Pour OrderTime on ne peut pas inventer des valeurs .
Pour channel et paymentType , sachant qu'ils sont des variables catégorielles on peut ajouter "inconnu" our "N/A" pour les valuers manquantes
l'imputation par 0 fait chuter la moyenne de 28,19 à 25,33 et gonfle l'écart-type (12,74 → 14,83) avec un minimum artificiel de 0. L'imputation par la médiane conserve la moyenne (28,19) mais comprime la dispersion (12,18).

Décision / Justification

Q8

Interprétation

Remplacer par 0 introduit des valeurs fausses (un prix de 0 n'existe pas) : la moyenne chute, l'écart-type explose, le minimum devient 0 et les agrégats (Cost, Revenue) sont sous-estimés.

La médiane préserve la tendance centrale et reste robuste aux valeurs extrêmes, mais elle réduit artificiellement la variance et ignore les liens entre variables.

Aucune imputation est préférable lorsque : la proportion de valeurs manquantes est élevée ; l'absence est informative (non mesuré, non applicable) ; la variable n'est pas utilisée dans l'analyse ; les valeurs manquantes ne sont pas aléatoires (risque de biais) ; ou lorsque le calcul peut simplement exclure les lignes concernée

_ Décision / Justification

Q9

```
Doublons exacts (lignes répétées) : 16
Lignes impliquées (originaux + copies) : 32
OrderID unique ? False | OrderID répétés : 16
OrderID répétés avec contenu différent : 0
```

	index	OrderID	Date	OrderTime	Region	ville	StoreID	Channel	customer	Produ
5	21	1006	1.725750e+18	13:33.6	North East	Manouba	15	Retail	507	
813	21	1006	1.725750e+18	13:33.6	North East	Manouba	15	Retail	507	
810	428	1037	1.756680e+18	41:04.8	North East	Zaghouan	12	Retail	507	
36	428	1037	1.756680e+18	41:04.8	North East	Zaghouan	12	Retail	507	
92	0	1093	1.736550e+18	16:33.6	South East	Medenine	13	Online	502	
808	0	1093	1.736550e+18	16:33.6	South East	Medenine	13	Online	502	

	Avant	Après	Écart	Écart %
Lignes	816.00	800.00	-16.00	-1.96
Quantité totale	8110.00	7999.00	-111.00	-1.37
Montant après remise	203345.68	200468.26	-2877.42	-1.42

Interprétation

les 16 lignes en double sont exactement les 16 OrderID répétés, avec un contenu identique. Ici, les deux contrôles donnent donc le même résultat, mais ce n'est pas toujours le cas : un OrderID répété avec un contenu différent peut être une correction ou une commande à plusieurs lignes, et il faudrait alors l'examiner.
Décision : je supprime les doublons exacts en gardant la première occurrence, et je ne touche pas aux OrderID en conflit.
Effet : les doublons gonflaient les totaux. Leur suppression retire 16 lignes (–1,96 %), 111 unités (–1,37 %) et 2 877 de montant (–1,42 %).

Q10

```
index            int64
OrderID          int64
Date           float64
OrderTime       object
Region          object
ville           object
StoreID          int64
Channel         object
customer         int64
ProductID        int64
Units            int64
UnitPrice      float64
disc           float64
prom              bool
PaymentType     object
```

```
Date convertie : datetime64[ns] | 2024-03-02 -> 2025-12-09
```

OrderTime_Format	lignes	pourcentage
MM:SS.d	566	70.8
Manquant	126	15.8
HH:MM:SS	108	13.5

OrderTime_Format	exemples
HH:MM:SS	[15:08:00, 19:43:24, 11:07:48]
MM:SS.d	[51:52.8, 41:04.8, 13:33.6]
Manquant	[]

Interprétation

la colonne OrderTime est inutilisable pour une analyse horaire. Seules 108 lignes (13,5 %) ont une heure complète (HH:MM:SS). La majorité, 566 lignes (70,8 %), est au format MM:SS.d, sans l'heure, sans doute tronquée à l'export. Les 126 restantes (15,8 %) sont vides. Je garde la colonne avec un indicateur de format, et j'utilise Date pour le temps.

Q11

	lignes concernées
Units <= 0	0
UnitPrice <= 0	0
disc < 0 ou > 1	0
disc > 0.5 (inhabituel)	0
Channel manquant	89
PaymentType manquant	57
Region manquante	0
ProductID absent du référentiel	88

```
prom : {False: 588, True: 212}

Channel : {'Online': 442, 'Retail': 269, nan: 89}

PaymentType : {'Credit': 259, 'Paypal': 250, 'Cash': 234, nan: 57}

disc : {0.0: 341, 0.2: 152, 0.1: 148, 0.25: 113, 0.3: 46}
Region : variantes de casse/espaces = 0
ville : variantes de casse/espaces = 0
Channel : variantes de casse/espaces = 0
PaymentType : variantes de casse/espaces = 0
ProductID absents : [210]
```

Interprétation

aucune valeur aberrante (Units et UnitPrice > 0, disc entre 0 et 0,3, prom booléen, pas de variantes de casse). Seuls points à noter : 89 manquants dans Channel, 57 dans PaymentType, et 88 lignes avec un ProductID 210 absent de products. Décision : je ne modifie aucune valeur ; les manquants passent en « Inconnu » (justification en Q7) et le ProductID 210 est conservé pour la jointure.

Q12

	Avant	Après	Écart	Écart %
Lignes	816.00	800.00	-16.00	-1.96
Valeurs manquantes	277.00	126.00	-151.00	-54.51
Quantité totale	8110.00	7999.00	-111.00	-1.37
Montant (UnitPrice×Units×(1−disc))	203345.68	200468.26	-2877.42	-1.42

```
Manquants restants par colonne : {'OrderTime': 126}
```

Interprétation

Lecture : −16 lignes (doublons) ; les valeurs manquantes passent de 277 à 126, uniquement `OrderTime` (laissée volontairement vide) ; `Channel` et `PaymentType` n'ont plus de NaN mais une modalité « Inconnu » explicite. Quantité −1,37 % et montant −1,42 %.

Risques de biais : le dédoublonnage suppose que les copies sont des erreurs ; les modalités « Inconnu » peuvent masquer des différences réelles entre canaux ou paiements ; l'heure reste inexploitable.

Décision / Justification

03

Transformation et création de variables

Questions couvertes : Q13-Q19

Q13

```
index unique après dédoublonnage : True | min/max : 0 799
Corrélation index / OrderID : 0.018

Colonnes restantes : ['OrderID', 'Date', 'OrderTime', 'Region', 'ville', 'StoreID', 'Channel', 'c
```

Interprétation

`index` est unique (0 à 799) après dédoublonnage, quasi non corrélé à `OrderID` (0,018) et identique dans les copies d'une même ligne : c'est un numéro de ligne technique issu de l'export, sans signification métier et redondant avec l'index pandas. Il est **supprimé** ;

`OrderID` reste la clé métier.

Décision / Justification

Q14

Q14 — Renommage

```
df = df.rename(columns={'ville': 'City', 'customer': 'CustomerID', 'disc': 'Discount', 'prom':
print(list(df.columns))
display(df.head(3))
```

[14] Python

```
['OrderID', 'Date', 'OrderTime', 'Region', 'City', 'StoreID', 'Channel', 'CustomerID', 'ProductID
```

	OrderID	Date	OrderTime	Region	City	StoreID	Channel	CustomerID	ProductID	Units	Ur
0	1001	2025-03-28	15:08:00	South West	Kebili	10	Retail	508	209	4	
1	1002	2025-11-09	51:52.8	Centre East	Monastir	11	Online	506	203	8	
2	1003	2025-06-20	19:43:24	Centre East	Mahdia	15	Online	502	202	7	

Interprétation

Les noms sont changés en format cohérent (même casse)
Les noms des colonnes sont significatifs .

Décision / Justification

Q15

```
df['Cost'] = df.UnitPrice * df.Units
display(df[['UnitPrice', 'Units', 'Cost']].head())
```

[15] Python

	UnitPrice	Units	Cost
0	28.72	4	114.88
1	33.77	8	270.16
2	31.08	7	217.56
3	30.39	15	455.85
4	32.31	15	484.65

Interprétation

`Cost` = montant brut de la ligne au prix unitaire indiqué (avant remise). Ce n'est pas un coût d'achat réel.

Décision / Justification

Q16

Q16 — Revenue

```
df['Revenue'] = df.UnitPrice * df.Units * (1 - df.Discount)
display(df[['UnitPrice', 'Units', 'Discount', 'Cost', 'Revenue']].head())
```

[16] Python

	UnitPrice	Units	Discount	Cost	Revenue
0	28.72	4	0.0	114.88	114.880
1	33.77	8	0.1	270.16	243.144
2	31.08	7	0.0	217.56	217.560
3	30.39	15	0.0	455.85	455.850
4	32.31	15	0.0	484.65	484.650

Interprétation

La remise est appliqué pour la colonne “Revenue”
On a affiché les 5 premières lignes seulement ici

Décision / Justification

Q17

	Total	Écart max (ligne) vs Final_Revenue
Revenue	200468.2560	NaN
Final_Revenue (promo après Discount)	197832.2615	0.0000
Promo avant Discount (multiplicatif)	197832.2615	0.0000
Promo avant Discount (additif : 1 − d − 0,05)	197486.0005	14.1303

```
Multiplicatif identique : True
Additif identique       : False
Lignes promo avec Discount > 0 : 122 sur 212
```

Interprétation

Calcul : Revenue est le montant après la remise Discount. Final_Revenue retire en plus 5 % pour les lignes en promotion. Le total passe de 200 468 à 197 832, soit −1,3 %.
Ordre des remises :

Si les remises se multiplient, l'ordre n'a aucune importance : le résultat est le même.

Si on les additionne (1 − Discount − 0,05), le total est un peu plus bas : 197 486. L'écart peut aller jusqu'à 14,13 par ligne.

Décision / Justification

Q18

```
{'Centre East': 144, 'North East': 144, 'Centre West': 140, 'South East': 138, 'South West': 124, 'North West': 110}
{'Centre': 284, 'South': 262, 'North': 254}
{'East': 426, 'West': 374}
```

Direction	East	West
Zone		
Centre	144	140
North	144	110
South	138	124

Interprétation

vérification avec tableau croisé :
totaux cohérents , sommes cohérentes , croisement complet (pas de valeurs vides)

Décision / Justification

Q19

Q19 — Vérifications et assertions

```python
for i in [0, 100, 500]:
    r = df.loc[i]
    cost = r.UnitPrice * r.Units
    rev = cost * (1 - r.Discount)
    fin = rev * 0.95 if r.PromoFlag else rev
    print(f'Ligne {i} : {r.UnitPrice} x {r.Units} = {cost:.2f} | remise {r.Discount} -> {rev:.2f} | promo {r.PromoFlag} -
          f'  (df : {r.Cost:.2f} / {r.Revenue:.2f} / {r.Final_Revenue:.2f})')
    assert np.isclose(cost, r.Cost) and np.isclose(rev, r.Revenue) and np.isclose(fin, r.Final_Revenue)

assert (df.Units > 0).all() and (df.UnitPrice > 0).all()
assert df.Discount.between(0, 1).all()
assert (df.Cost > 0).all() and (df.Revenue >= 0).all() and (df.Final_Revenue >= 0).all()
assert (df.Revenue <= df.Cost + 1e-9).all()
assert (df.Final_Revenue <= df.Revenue + 1e-9).all()
assert df.OrderID.is_unique
assert df[['Cost', 'Revenue', 'Final_Revenue']].notna().all().all()
print('\nToutes les assertions sont validées.')
```

Python

```
Ligne 0 : 28.72 x 4 = 114.88 | remise 0.0 -> 114.88 | promo False -> 114.88  (df : 114.88 / 114.88 / 114.88)
Ligne 100 : 22.78 x 1 = 22.78 | remise 0.25 -> 17.09 | promo False -> 17.09  (df : 22.78 / 17.09 / 17.09)
Ligne 500 : 45.29 x 8 = 362.32 | remise 0.25 -> 271.74 | promo True -> 258.15  (df : 362.32 / 271.74 / 258.15)

Toutes les assertions sont validées.
```

Interprétation

Les assertions manuelles valent surtout par ce qu'elles garantissent : elles transforment une impression de justesse en preuve vérifiable.

Décision / Justification

04

Statistiques descriptives et exploration graphique

Questions couvertes : Q20-Q26

Q20

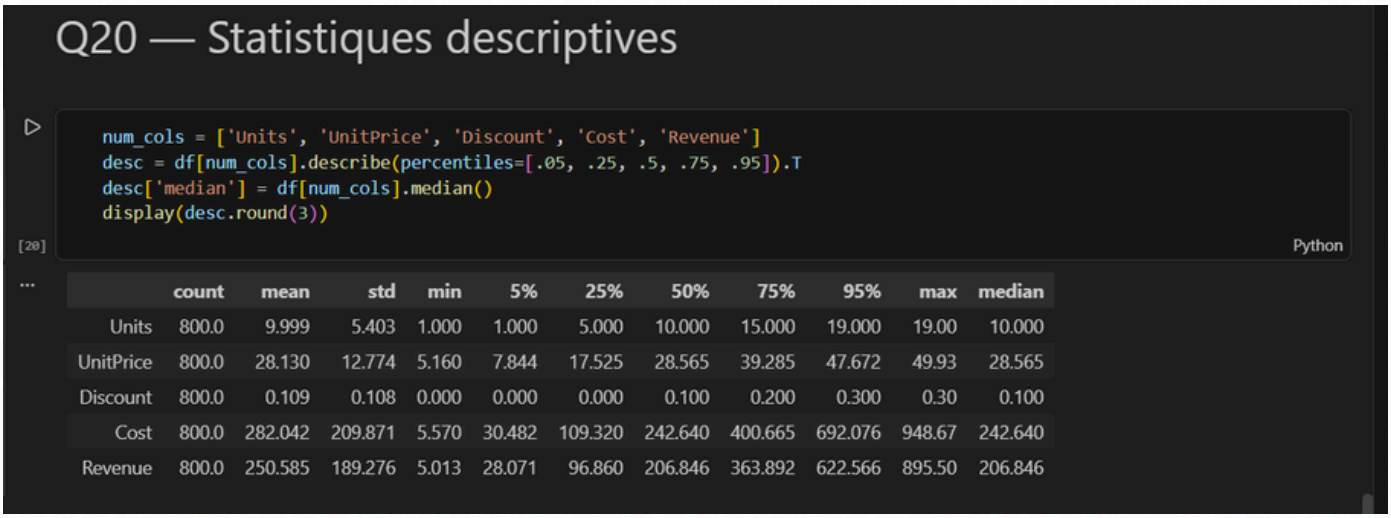

	count	mean	std	min	5%	25%	50%	75%	95%	max	median
Units	800.0	9.999	5.403	1.000	1.000	5.000	10.000	15.000	19.000	19.00	10.000
UnitPrice	800.0	28.130	12.774	5.160	7.844	17.525	28.565	39.285	47.672	49.93	28.565
Discount	800.0	0.109	0.108	0.000	0.000	0.000	0.100	0.200	0.300	0.30	0.100
Cost	800.0	282.042	209.871	5.570	30.482	109.320	242.640	400.665	692.076	948.67	242.640
Revenue	800.0	250.585	189.276	5.013	28.071	96.860	206.846	363.892	622.566	895.50	206.846

Interprétation

`Units` (1 à 19) et `UnitPrice` (5,16 à 49,93) sont symétriques (moyenne ≈ médiane : 10 et 28).

`Discount` : 57 % des lignes ont une remise, de 0,1 à 0,3.

`Cost` et `Revenue` sont asymétriques à droite (moyenne 282 > médiane 243 ; 251 > 207) avec un maximum de 949 et 896, car ils combinent quantité et prix.

Décision / Justification

Q21

	Variable	Q1	Q3	IQR	Borne basse	Borne haute	Outliers	% lignes
0	Units	5.00	15.00	10.00	-10.00	30.00	0	0.00
1	UnitPrice	17.53	39.28	21.76	-15.11	71.92	0	0.00
2	Revenue	96.86	363.89	267.03	-303.69	764.44	9	1.12

Lecture : aucune valeur atypique pour `Units` et `UnitPrice` (bornes −10 / 30 et −15,1 / 71,9, toutes les valeurs sont à l'intérieur) ; 9 observations (1,12 %) de `Revenue` dépassent 764,4, toutes liées à de fortes quantités à prix élevé.

Interprétation

aucune valeur atypique pour `Units` et `UnitPrice` (bornes −10 / 30 et −15,1 / 71,9, toutes les valeurs sont à l'intérieur) ; 9 observations (1,12 %) de `Revenue` dépassent 764,4, toutes liées à de fortes quantités à prix élevé.

Décision / Justification

Q22

	Variable	Outliers IQR	Outliers |z|>3	Communs	Asymétrie
0	Units	0	0	0	0.00
1	UnitPrice	0	0	0	-0.05
2	Revenue	9	4	4	0.90

	OrderID	Units	UnitPrice	Discount	Revenue	z
408	1409	18	49.75	0.0	895.50	3.41
576	1577	19	49.93	0.1	853.80	3.19
781	1782	18	47.28	0.0	851.04	3.17
305	1306	18	47.27	0.0	850.86	3.17
505	1506	18	44.76	0.0	805.68	2.93
581	1582	17	46.18	0.0	785.06	2.83
182	1183	16	48.81	0.0	780.96	2.80
235	1236	17	45.66	0.0	776.22	2.78
615	1616	16	48.14	0.0	770.24	2.75

Interprétation

Lecture: pour `Revenue`, l'IQR signale 9 points et le score z seulement 4 (les 4 sont communs) ; la distribution étant asymétrique à droite (asymétrie 0,90), l'IQR est plus sensible. `Units` et `UnitPrice` n'ont aucun outlier avec les deux méthodes.
- IQR : basé sur les quantiles, robuste aux valeurs extrêmes elles-mêmes et sans hypothèse de distribution ; mais il peut signaler beaucoup de points sur des distributions asymétriques.
-Score z : simple, mais moyenne et écart-type sont eux-mêmes sensibles aux extrêmes (effet de masquage) et il suppose une distribution proche de la normale ; il est peu sensible sur de petits échantillons.
- Une valeur extrême n'est pas systématiquement supprimée: elle peut être légitime on la conserve si elle est plausible.

Décision / Justification

Q23

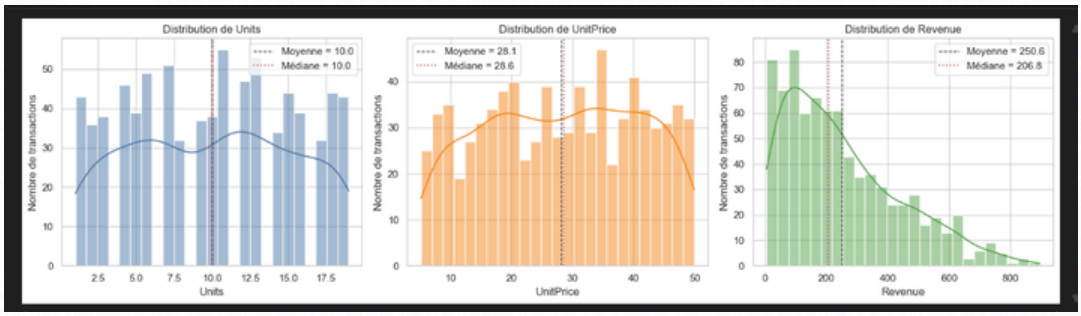

Interprétation

`Units` et `UnitPrice` sont quasi uniformes (moyenne ≈ médiane, pas de queue), tandis que `Revenue` est asymétrique à droite : la majorité des transactions est sous 400, avec une longue queue jusqu'à environ 900.

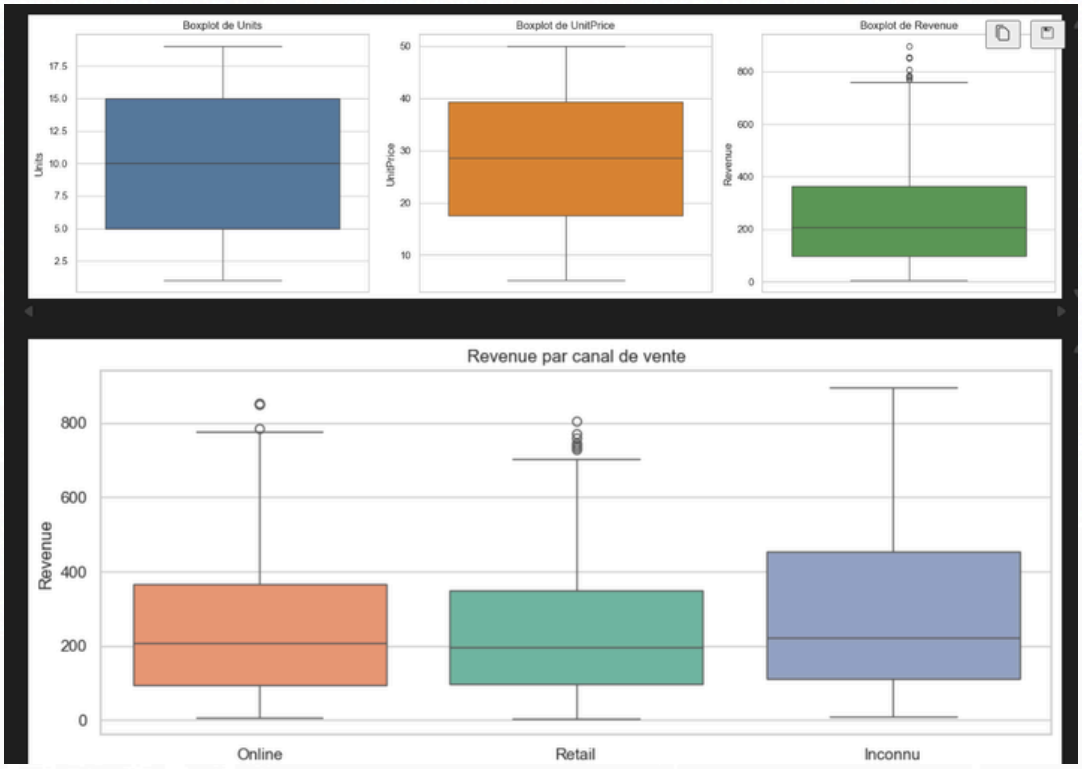

les boxplots de `Units` et `UnitPrice` sont symétriques sans point extérieur ; `Revenue` montre une médiane de 207 et quelques points au-delà de 764. Par canal, les médianes sont proches (Online 209, Retail 195, Inconnu 221) : les distributions se recouvrent largement.

Q24

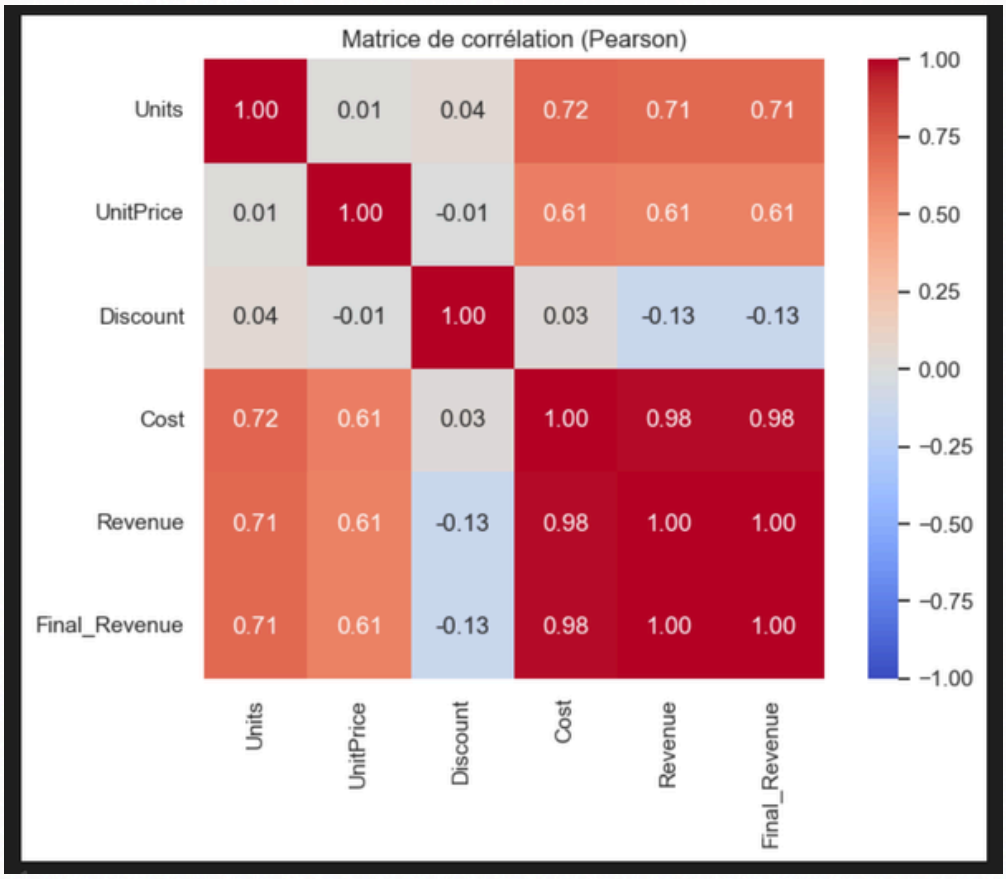

Interprétation

les corrélations les plus fortes sont mécaniques : `Revenue`–`Final_Revenue` (0,999) et `Cost`–`Revenue` (0,979). Les relations « réelles » sont modérées : `Units`–`Cost` (0,72) et `UnitPrice`–`Cost` (0,61) ; `Units` et `UnitPrice` sont indépendantes (0,01) ; `Discount` est faiblement liée à `Revenue` (–0,13).
Une corrélation mesure une association linéaire, pas une relation de cause à effet : une variable tierce, la coïncidence ou un sens de causalité inverse peuvent l'expliquer. Par ailleurs, `Cost`, `Revenue` et `Final_Revenue` sont **calculées à partir de** `Units`, `UnitPrice` et `Discount` : leurs corrélations élevées sont mécaniques (redondance de l'information) et ne constituent pas un résultat d'analyse.

Q25

	Écart-type	Moyenne	CV (écart-type / moyenne)	IQR / médiane
Discount	0.108	0.109	0.986	2.000
Revenue	189.276	250.585	0.755	1.291
Cost	209.871	282.042	0.744	1.201
Units	5.403	9.999	0.540	1.000
UnitPrice	12.774	28.130	0.454	0.762

Interprétation

comparer les écarts-types n'aurait pas de sens (`Cost` : 210 contre `Discount` : 0,11, échelles différentes).
Le coefficient de variation (écart-type / moyenne) est sans unité :

`Discount` ressort en tête (0,99), mais sa moyenne est proche de 0 avec beaucoup de zéros, ce qui gonfle le CV.

Parmi les variables monétaires, `Revenue` (0,76) est plus dispersée que `Cost` (0,74), `Units` (0,54) et `UnitPrice` (0,45).

L'IQR / médiane confirme le classement.

Décision / Justification

Q26

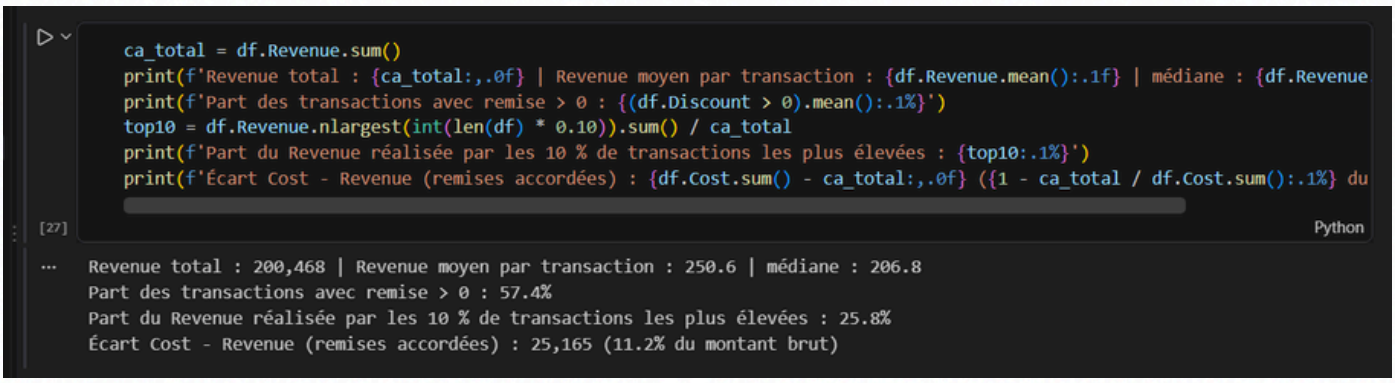

```
ca_total = df.Revenue.sum()
print(f'Revenue total : {ca_total:,.0f} | Revenue moyen par transaction : {df.Revenue.mean():.1f} | médiane : {df.Revenue
print(f'Part des transactions avec remise > 0 : {(df.Discount > 0).mean():.1%}')
top10 = df.Revenue.nlargest(int(len(df) * 0.10)).sum() / ca_total
print(f'Part du Revenue réalisée par les 10 % de transactions les plus élevées : {top10:.1%}')
print(f'Écart Cost - Revenue (remises accordées) : {df.Cost.sum() - ca_total:,.0f} ({1 - ca_total / df.Cost.sum():.1%} du
```

[27] Python

```
Revenue total : 200,468 | Revenue moyen par transaction : 250.6 | médiane : 206.8
Part des transactions avec remise > 0 : 57.4%
Part du Revenue réalisée par les 10 % de transactions les plus élevées : 25.8%
Écart Cost - Revenue (remises accordées) : 25,165 (11.2% du montant brut)
```

Interprétation

(1) le Revenue total est de 200 468 pour 800 transactions (moyenne 250,6, médiane 206,8) et 57,4 % des transactions bénéficient d'une remise, soit 11,2 % du montant brut accordé en remises ;
(2) les 10 % de transactions les plus élevées réalisent 25,8 % du Revenue.

Limite : l'analyse descriptive ne dit rien sur les causes, `Cost` n'est pas un coût d'achat (pas de marge), l'heure est peu fiable, et les modalités « Inconnu » (Channel 11 %, PaymentType 7 %) ainsi que le ProductID 210 absent du référentiel (11 % des lignes) restent à valider.

05

Interrogations et filtrage avec Pandas

Questions couvertes : Q27-Q31

Q27

```
ventes_q27 = df[df.Units > 10]
print('Lignes retournées :', len(ventes_q27))
display(ventes_q27.head(10))
```

[28] Python

```
Lignes retournées : 391
```

	OrderID	Date	OrderTime	Region	City	StoreID	Channel	CustomerID	ProductID	Units	UnitPrice	Discount	PromoFla
3	1004	2025-04-29	NaN	Centre West	Kasserine	15	Online	506	208	15	30.39	0.0	Fals
4	1005	2025-04-03	41:04.8	Centre East	Sousse	11	Online	501	209	15	32.31	0.0	Fals
5	1006	2024-09-07	13:33.6	North East	Manouba	15	Retail	507	205	12	36.24	0.2	Fals
7	1008	2024-12-13	11:07:48	Centre West	Kasserine	12	Online	503	200	15	30.95	0.0	Fals
8	1009	2024-04-05	57:55.2	Centre West	Gafsa	12	Online	502	202	11	5.49	0.2	Fals
10	1011	2024-07-27	NaN	North West	Jendouba	13	Retail	503	209	14	41.54	0.1	Tru
11	1012	2024-11-05	17:31.2	North East	Ariana	11	Online	506	209	12	6.61	0.1	Fals
12	1013	2024-06-02	NaN	North East	Bizerte	15	Inconnu	506	208	14	36.61	0.0	Tru
13	1014	2024-05-25	45:55.2	North West	Ayn Draham	10	Retail	503	209	17	20.70	0.2	Fals
15	1016	2025-06-09	48:07.2	South East	Medenine	12	Online	502	203	11	49.17	0.0	Fals

Interprétation

Lignes retournées : 391
on a affiché 10 lignes seulement

Décision / Justification

Q28

```
ventes_q28 = df[((df.PaymentType == 'Credit') | (df.PaymentType == 'Paypal')) & (df.Revenue >= 200)]
print('Lignes retournées :', len(ventes_q28))
display(ventes_q28.head(10))
```

[29] Python

```
Lignes retournées : 256
```

	OrderID	Date	OrderTime	Region	City	StoreID	Channel	CustomerID	ProductID	Units	UnitPrice	Discount	PromoFla
1	1002	2025-11-09	51:52.8	Centre East	Monastir	11	Online	506	203	8	33.77	0.1	Tru
2	1003	2025-06-20	19:43:24	Centre East	Mahdia	15	Online	502	202	7	31.08	0.0	Fals
3	1004	2025-04-29	NaN	Centre West	Kasserine	15	Online	506	208	15	30.39	0.0	Fals
4	1005	2025-04-03	41:04.8	Centre East	Sousse	11	Online	501	209	15	32.31	0.0	Fals
5	1006	2024-09-07	13:33.6	North East	Manouba	15	Retail	507	205	12	36.24	0.2	Fals
10	1011	2024-07-27	NaN	North West	Jendouba	13	Retail	503	209	14	41.54	0.1	Tru
12	1013	2024-06-02	NaN	North East	Bizerte	15	Inconnu	506	208	14	36.61	0.0	Tru
13	1014	2024-05-25	45:55.2	North West	Ayn Draham	10	Retail	503	209	17	20.70	0.2	Fals
14	1015	2024-03-24	04:04.8	South West	Kebili	12	Online	507	210	8	46.30	0.0	Fals
15	1016	2025-06-09	48:07.2	South East	Medenine	12	Online	502	203	11	49.17	0.0	Fals

Interprétation

Lignes retournées : 256
on a affiché 10 lignes seulement

Décision / Justification

Q29

	lignes	pourcentage
Remise ET promo	122	15.2
Remise seulement	337	42.1
Promo seulement	90	11.2
Aucune des deux	251	31.4

```
Une seule condition vraie (remise XOR promo) : 427 | Somme des 4 cas = 800 = nb de lignes 800
```

	OrderID	Date	OrderTime	Region	City	StoreID	Channel	CustomerID	ProductID	Units	UnitPrice	Discount	PromoFla
1	1002	2025-11-09	51:52.8	Centre East	Monastir	11	Online	506	203	8	33.77	0.10	Tru
10	1011	2024-07-27	NaN	North West	Jendouba	13	Retail	503	209	14	41.54	0.10	Tru
22	1023	2025-03-20	20:28.8	South East	Gabes	12	Online	502	205	2	18.08	0.20	Tru
26	1027	2025-04-06	20:48:24	South East	Gabes	15	Retail	508	203	15	19.15	0.25	Tru
35	1036	2025-11-28	40:14.4	Centre West	Gafsa	10	Online	501	203	4	9.37	0.20	Tru
45	1046	2025-10-23	17:20:24	North West	Ayn Draham	13	Online	502	209	13	49.53	0.25	Tru
48	1049	2024-12-08	33:02.4	North East	Bizerte	14	Retail	508	208	2	10.86	0.20	Tru
49	1050	2025-10-01	45:43.2	North West	Ayn Draham	11	Inconnu	507	208	5	22.79	0.20	Tru
57	1058	2025-06-18	58:31.2	North East	Ben Arous	13	Online	507	202	5	23.77	0.25	Tru
62	1063	2024-12-02	11:07:24	South West	Gafsa	10	Retail	507	210	5	47.23	0.30	Tru

Interprétation

122 ventes cumulent remise et promotion ; 337 ont une remise seule et 90 une promotion seule, soit 427 avec une seule condition vraie (les 4 cas totalisent bien 800). `PromoFlag` n'implique donc pas `Discount` > 0

Décision / Justification

Q30

```
Seuil (quantile 75 % de Units) : 15.0
Part des ventes avec Units >= seuil : 25.2%
Lignes retournées : 60
```

Interprétation

le seuil est le 3e quartile de `Units` (15), calculé sur toutes les ventes ; on retient `Units ≥ 15` (la variable étant discrète, cela couvre 25,2 % des ventes au lieu de 25 %). 60 ventes de North East ou South West remplissent la condition.

explication pourquoi 25.2% au lieu de 25%

- Plusieurs ventes ont exactement 15 unités, et on ne peut pas en garder seulement une partie.
- On les garde toutes, donc on obtient un peu plus que 25 % : 25,2 %.

Décision / Justification

Q31

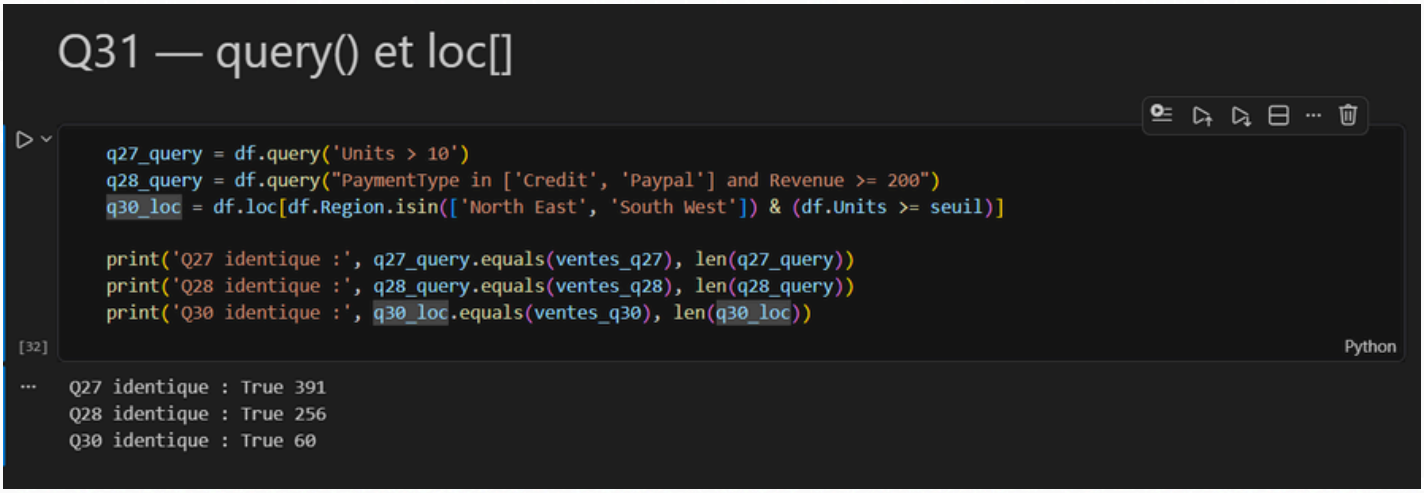

Interprétation

Les masques booléens sont très flexibles mais verbeux : il faut répéter df. partout, mettre des parenthèses et on peut facilement en oublier.
query() a une syntaxe proche du langage naturel (and, in), donc plus lisible pour des filtres multiples, mais comme elle utilise des chaînes de caractères, elle est moins vérifiable à l'avance et demande @ pour utiliser des variables Python.

loc[] permet de filtrer les lignes et de choisir les colonnes en une seule instruction, et il autorise aussi l'affectation sans SettingWithCopyWarning. Ici, les trois approches donnent exactement les mêmes résultats : query() est la plus lisible pour des conditions simples, et les masques conviennent mieux aux conditions complexes ou dynamiques.

Décision / Justification

06

Agrégations et analyse par segments

Questions couvertes : Q32-Q37

Q32

Region	Transactions	Quantite_totale	Revenue_total	Revenue_moyen	Final_Revenue_total
Centre East	144	1532	41470.7	288.0	40802.3
Centre West	140	1458	35143.1	251.0	34733.9
North East	144	1440	34562.0	240.0	34229.7
South East	138	1314	32067.8	232.4	31604.2
North West	110	1138	29832.7	271.2	29469.1
South West	124	1117	27392.0	220.9	26993.1

Interprétation

`Centre East` arrive en tête avec un Revenue de 41 471 pour 144 transactions et 1 532 unités, devant `Centre West` (35 143) et `North East` (34 562) ; `South West` ferme le classement (27 392). Le `Revenue_moyen` ne suit pas le même ordre : `North West` (271) est deuxième alors qu'elle n'a que 110 transactions. `Final_Revenue` est partout inférieur à `Revenue` (–1,3 % au total) à cause de la remise promotionnelle de 5 %. La somme des régions égale bien le Revenue total (200 468).

_ Décision / Justification

Q33

Region	Channel	Transactions	Quantite_totale	Revenue_total
Centre East	Inconnu	14	134	3553.1
	Online	84	928	26109.0
	Retail	46	470	11808.7
Centre West	Inconnu	17	218	6749.1
	Online	75	718	16318.1
	Retail	48	522	12075.9
North East	Inconnu	15	176	4349.5
	Online	76	742	17606.4
	Retail	53	522	12606.1
North West	Inconnu	11	90	2437.7
	Online	61	691	18107.4
	Retail	38	357	9287.6
South East	Inconnu	15	149	3552.2
	Online	79	732	18598.6
	Retail	44	433	9917.0
South West	Inconnu	17	172	3975.3
	Online	67	577	14267.3
	Retail	40	368	9149.3

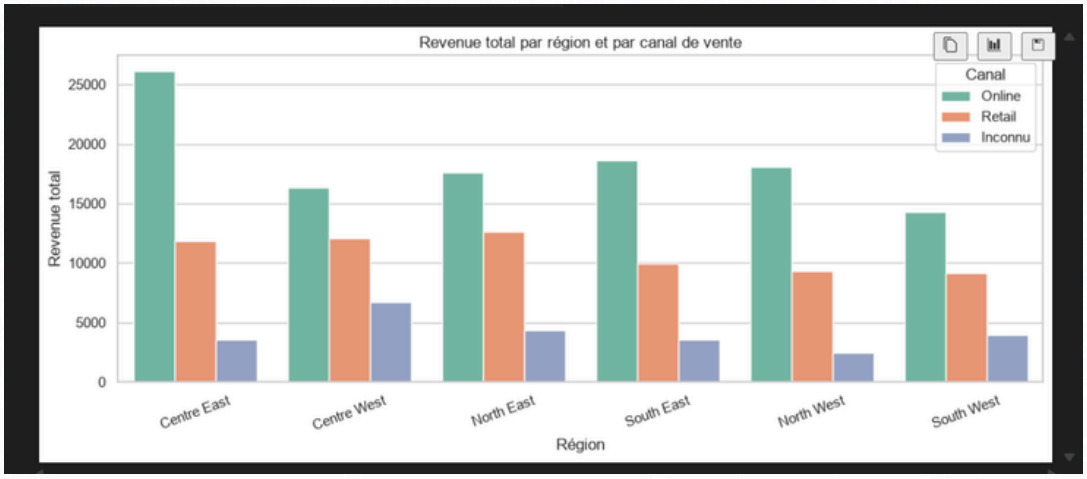

Interprétation

Online domine dans les six régions, avec sa plus forte cellule à Centre East (26 109, soit 13,0 % du Revenue total). Le poids du Retail varie : 74 % du Revenue Online à Centre West, mais seulement 51 % à North West. South West a le plus faible Revenue Online (14 267). Enfin, la modalité « Inconnu » pèse jusqu'à 6 749 à Centre West, ce qui peut fausser la lecture du canal dans cette région.

Q34

```
Ventes avec Cost > 100 : 620 sur 800
PaymentType manquant (données dédoublonnées) : 57 | NaN restants dans df : 0 | modalité « Inconnu » dans Cost > 100 : 47
```

PaymentType	Transactions	Revenue_total
Cash	191	60112.4
Credit	203	59817.7
Paypal	179	58460.8
Inconnu	47	13356.1

```
Revenue (Cost > 100) avec « Inconnu » : 191747.0 | groupby sans traitement : 178390.8 | ventes perdues : 13356.1
```

Interprétation

620 ventes sur 800 (77,5 %) ont un `Cost` > 100. Les trois modes connus sont très proches : `Cash` 60 112 (191 transactions), `Credit` 59 818 (203) et `Paypal` 58 461 (179). Traitement des manquants : les 57 `PaymentType` manquants (après dédoublonnage) ont reçu la modalité « Inconnu » en Q7/Q11 ; 47 d'entre elles ont un `Cost` > 100 et représentent 13 356 de Revenue. Sans ce traitement, `groupby()` ignorerait silencieusement les `NaN` et ces 13 356 (7,0 % du total filtré) disparaîtraient du tableau : le total serait faux (178 391 au lieu de 191 747).

Décision / Justification

Q35

Par catégorie

Category	Transactions	Quantite_totale	Revenue_total	Revenue_moyen	Part Revenue %
Electronics	239	2479	60503.59	253.15	30.18
Household	123	1253	33133.56	269.38	16.53
Personal Care	113	1173	30007.36	265.55	14.97
Accessories	119	1156	27059.32	227.39	13.50
Digital Products	118	1060	26241.03	222.38	13.09
Non référencé	88	878	23523.39	267.31	11.73

Par catégorie et produit

Category	ProductName	Transactions	Quantite_totale	Revenue_total	Revenue_moyen	Part Revenue %
Household	cleaning products	123	1253	33133.56	269.38	16.53
Electronics	iphone	121	1239	30563.09	252.59	15.25
Personal Care	Shampoo	113	1173	30007.36	265.55	14.97
Electronics	Computer	118	1240	29940.50	253.73	14.94
Accessories	watch	119	1156	27059.32	227.39	13.50
Digital Products	E-book	118	1060	26241.03	222.38	13.09
Non référencé	Non référencé	88	878	23523.39	267.31	11.73

```
ProductID sans correspondance : [210]
Impact : 88 lignes (11.0%), Revenue 23,523 (11.7% du total), quantité 878 (11.0%)
Produits du référentiel sans aucune vente : ['Online course', 'Handbag', 'blender', 'toothpaste']
```

Interprétation

- Electronics est la première catégorie avec 30,2 % du Revenue (iphone 15,3 %, Computer 14,9 %).
- Household arrive ensuite (16,5 %), avec cleaning products comme meilleur produit (33 134).

- Le ProduitID 210 est le dernier des sept produits vendus en Revenue total, mais le 3ᵉ en Revenue moyen par ligne (267).
- Online course, Handbag, blender et toothpaste n'ont aucune vente.

Q36

Region	Part du Revenue (%)
Centre East	20.69
Centre West	17.53
North East	17.24
South East	16.00
North West	14.88
South West	13.66

```
Somme des parts : 100.0 %
Lignes sans Region (exclues du calcul) : 0
```

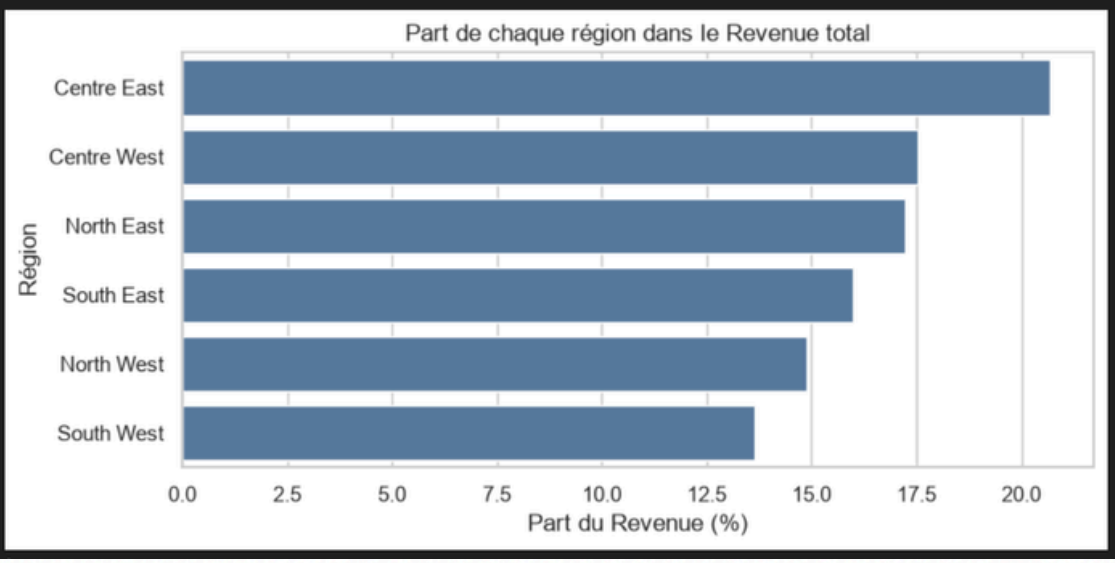

Interprétation

`Centre East` représente 20,7 % du Revenue, `South West` 13,7 %. Les six parts totalisent 100,00 % : aucune ligne n'a de `Region` manquante, donc aucune n'est exclue du calcul. Si des lignes avaient été exclues, il aurait fallu calculer les parts sur le total retenu et le préciser, sinon la somme n'aurait pas été de 100 %.

07

Jointures et contrôle de l’intégrité

Questions couvertes : Q38-Q42

Q38

```
Lignes de ventes avant la jointure : 800
Lignes après jointure interne      : 712 | lignes perdues : 88
Revenue avant : 200468.3 | après : 176944.9 | perdu : 23523.4
```

Interprétation

La jointure interne (inner join) permet de relier les ventes à la table de référence des produits en conservant uniquement les lignes dont le ProductID existe dans les deux tables. Sur les 800 ventes de sales_apres, 712 sont conservées, tandis que 88 sont exclues, soit 11 % des ventes. Ces lignes correspondent au ProductID 210, absent de la table products. Ainsi, cette jointure permet d'obtenir des données cohérentes pour analyser les produits référencés, mais elle entraîne une perte d'informations. Il est donc préférable d'utiliser une jointure gauche (left join) lorsqu'on souhaite conserver toutes les ventes et identifier les produits manquants dans le référentiel.

Q39

```
Lignes après jointure gauche : 800 (= nombre de ventes : True )
Ventes sans correspondance   : 88 (11.0%)
ProductID concernés          : [210]
```

	OrderID	Region	ProductID	Units	UnitPrice	Revenue
9	1010	North West	210	3	44.48	133.440
14	1015	South West	210	8	46.30	370.400
18	1019	South East	210	5	9.68	43.560
25	1026	South West	210	10	17.36	173.600
30	1031	Centre West	210	15	25.71	347.085

Interprétation

La jointure gauche (left join) conserve les 800 ventes de sales_apres, même lorsque leur ProductID n'existe pas dans le référentiel products. Parmi ces ventes, 88 lignes ne trouvent pas de correspondance : elles concernent le ProductID 210, absent de la table des produits. Contrairement à la jointure interne de la question précédente, la jointure gauche ne supprime donc aucune vente. Elle permet de préserver les données commerciales tout en identifiant les références produit manquantes. Il est recommandé de vérifier l'origine du ProductID 210 et de compléter ou corriger le référentiel avant de réaliser une analyse détaillée par produit.

Q40

```
ProductID unique dans products ? True | doublons : 0
validate="many_to_one" : OK, 800 lignes

Avec un doublon dans le référentiel : MergeError - Merge keys are not unique in right dataset; not a many-to-one merge
Sans validate : lignes 918 au lieu de 800 | Revenue 226709.3 au lieu de 200468.3
```

Interprétation

La table products contient 10 produits et 10 valeurs distinctes de ProductID, sans doublon. La clé ProductID est donc unique dans le référentiel. Le paramètre validate="many_to_one" vérifie que plusieurs ventes peuvent correspondre à un même produit, mais qu'un identifiant produit ne désigne qu'une seule ligne dans products. La jointure gauche doit ainsi conserver les 800 lignes de sales_apres. Si le référentiel contenait des doublons de ProductID, une même vente pourrait être répétée plusieurs fois après la jointure, ce qui fausserait les sommes et les statistiques. Ce contrôle confirme donc la cohérence de la cardinalité attendue, même si les 88 ventes associées au ProductID 210 restent sans correspondance dans le référentiel.

Q41

_merge	lignes
both	712
left_only	88
right_only	4

```
left_only  : ventes dont le ProductID est absent du référentiel : 88
right_only : produits du référentiel sans aucune vente          : 4
both       : ventes avec correspondance                         : 712
```

Interprétation

Le paramètre indicator=True ajoute la colonne _merge, qui indique l'origine de chaque ligne après la jointure. On obtient 712 lignes avec la catégorie both (89 %), correspondant aux ventes dont le produit existe dans le référentiel, et 88 lignes avec left_only (11 %), correspondant aux ventes sans produit référencé. La catégorie right_only est absente, car la jointure gauche conserve les ventes et non les produits isolés du référentiel. Les 88 ventes non appariées concernent le ProductID 210. Il est recommandé de vérifier cet identifiant auprès de la source des données, puis de corriger ou compléter le référentiel products si nécessaire. En attendant, ces ventes doivent être conservées et signalées afin d'éviter de perdre des informations ou de fausser les analyses par produit.

Q42

Interprétation

Une jointure gauche entre sales et products s'appuie sur ProductID : elle ne relie que des ventes à des produits. Elle ne dit rien sur les clients, pour deux raisons : (1) le fichier sales ne contient, par construction, que des clients **ayant acheté** (chaque CustomerID y apparaît au moins une fois ; il n'y en a que 6 distincts) ; un client sans achat n'y figure pas et ne peut donc pas être détecté ; (2) la clé de jointure n'est pas CustomerID.

Pour identifier les clients inactifs, il faudrait un **référentiel clients** complet (CRM ou fichier customers.csv avec CustomerID, date d'inscription, etc.). On ferait alors une jointure gauche clients → ventes sur CustomerID avec indicator=True : les lignes left_only sont les clients sans aucun achat (anti-jointure). Une période d'observation et une date d'inscription seraient aussi utiles pour distinguer les clients inactifs des clients très récents.

08

Analyse métier et recommandations

Questions couvertes : Q43-Q48

Q43

Region	Revenue_total	Part Revenue %	Transactions	Quantite_totale	Revenue_moyen	Unités / transaction	Revenue / unité
Centre East	41470.68	20.69	144	1532	287.99	10.64	27.07
Centre West	35143.06	17.53	140	1458	251.02	10.41	24.10
North East	34562.02	17.24	144	1440	240.01	10.00	24.00
South East	32067.80	16.00	138	1314	232.38	9.52	24.40
North West	29832.74	14.88	110	1138	271.21	10.35	26.22
South West	27391.95	13.66	124	1117	220.90	9.01	24.52

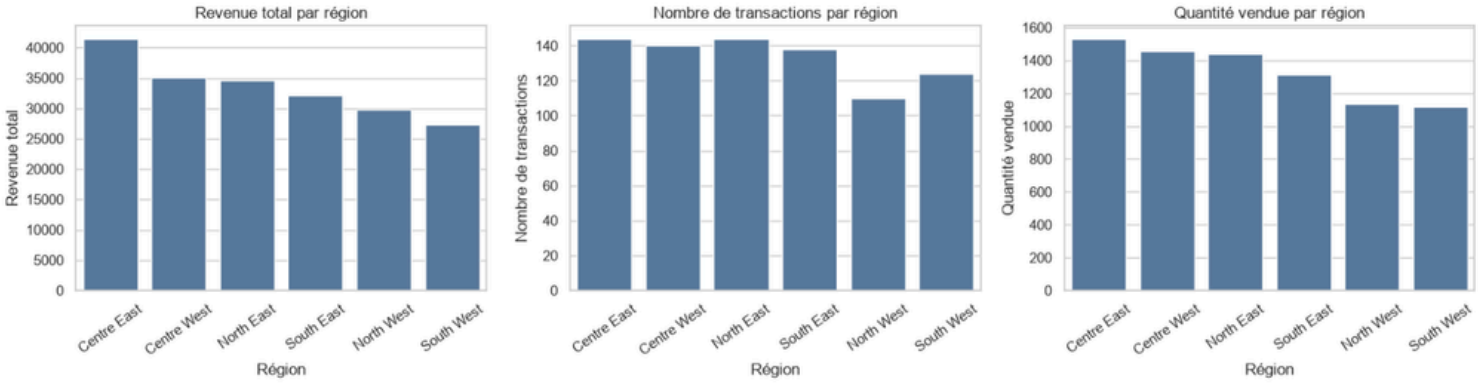

Interprétation

La région Centre East génère le chiffre d'affaires le plus élevé, avec 41 471, soit 20,7 % du total. Elle compte 144 transactions et 1 532 unités vendues. Son Revenue moyen est d'environ 288 par transaction, supérieur à la moyenne globale de 250,6. Sa performance s'explique par la combinaison du volume des ventes et du revenu par transaction.

Q44

PaymentType	Transactions	Revenue_total	Revenue_moyen	Part Revenue %
Credit	259	62667.19	241.96	31.26
Cash	234	62163.41	265.66	31.01
Paypal	250	61844.78	247.38	30.85
Inconnu	57	13792.87	241.98	6.88

```
Test de Kruskal-Wallis sur Revenue (modes connus) : H = 2.64, p-value = 0.267
Écart entre les deux premiers modes : 503.8 | Revenue des ventes « Inconnu » : 13792.9
```

Interprétation

Le paiement par Credit arrive en tête avec 62 667 de Revenue, suivi de Cash (62 163) et PayPal (61 845). Cependant, Cash présente le revenu moyen par transaction le plus élevé, soit 265,7. Les différences entre les trois modes connus ne sont pas statistiquement significatives. De plus, les 57 transactions dont le paiement est inconnu représentent 13 793 de Revenue et peuvent modifier le classement.

Q45

Indice (moyenne des régions = 100)	Revenue total	Transactions	Revenue moyen	Unités / transaction	Revenue / unité
Centre East	124	108	115	107	108
Centre West	105	105	100	104	96
North East	103	108	96	100	96
South East	96	103	93	95	97
North West	89	82	108	104	105
South West	82	93	88	90	98

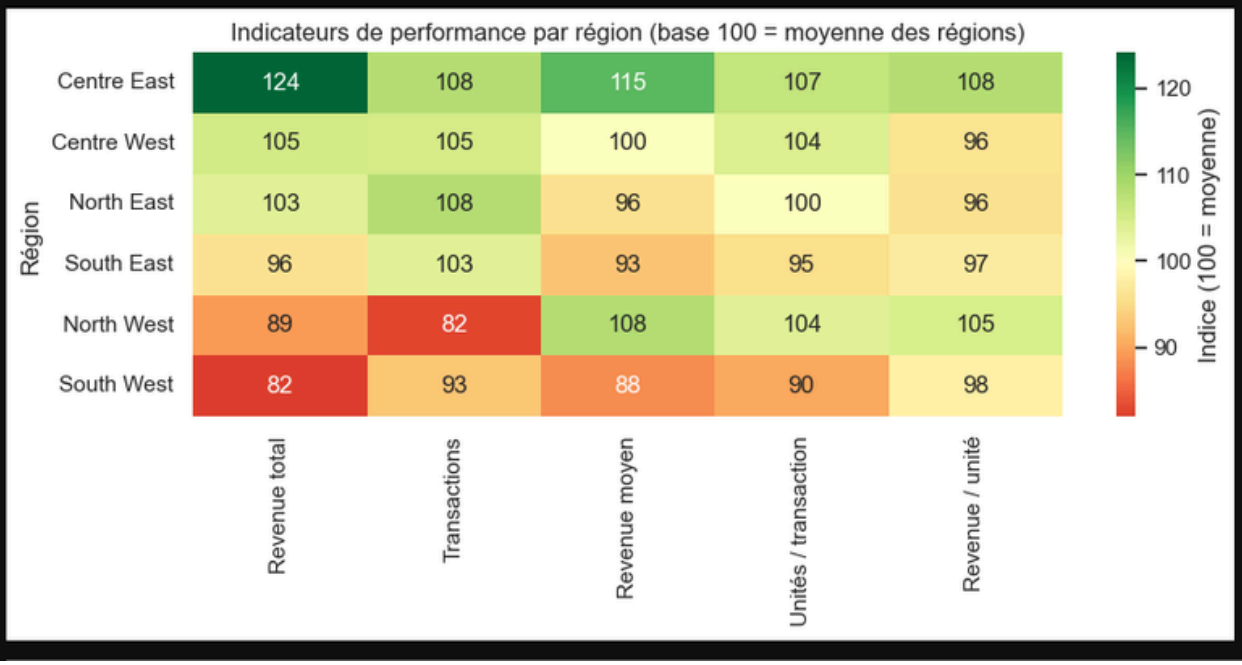

Interprétation

La région South West est le segment le plus faible, avec 27 392 de Revenue. Elle réalise environ 9 unités par transaction, contre 10 en moyenne, et un revenu moyen de 221, contre 251 globalement. Son revenu par unité reste proche de la moyenne. Le retard semble donc davantage lié aux quantités vendues par commande et au nombre de transactions qu'au prix unitaire.
La région North West présente aussi un Revenue total inférieur à la moyenne, mais principalement en raison de son faible nombre de transactions. Les deux régions nécessitent donc des actions différentes.

Q46

PromoFlag	Transactions	Quantite_moyenne	Revenue_moyen	Final_Revenue_total	Remise_moyenne	Prix_unitaire_moyen
Sans promo	588	10.03	251.27	147748.37	0.11	28.03
Avec promo	212	9.92	248.68	50083.90	0.11	28.39

```
Mann-Whitney sur Units (promo vs sans promo) : p-value = 0.821
Mann-Whitney sur Revenue (promo vs sans promo) : p-value = 0.857
Part de promotions par région : {'Centre East': 29.9, 'Centre West': 24.3, 'North East': 24.3, 'North West': 20.9, 'South East': 28.3, 'South West': 30.
6}
```

Interprétation

Les promotions concernent 212 transactions, soit 26,5 % du total. Le Revenue moyen est de 248,7 avec promotion, contre 251,3 sans promotion. Les quantités moyennes sont également proches : 9,92 contre 10,03. Les tests statistiques ne montrent pas de différence significative entre les deux groupes.
Il n'est donc pas possible d'affirmer que les promotions augmentent les ventes. Des tests A/B seraient nécessaires pour mesurer leur effet réel.

Q47

1. **Remonter le panier moyen de South West**
   - **Observation** : South West est dernière avec 27 392 de Revenue (13,7 %), 9,0 unités par transaction contre 10 en moyenne, et un Revenue moyen de 221 contre 251 en moyenne ; son prix par unité (24,5) est pourtant dans la moyenne.
   - **Recommandation** : cibler les quantités par commande (offres de lot, vente additionnelle, seuils de livraison gratuite) plutôt que les prix, et fixer un objectif de 10 unités par transaction.
   - **Limite / vérification** : l'analyse ne dispose ni du trafic, ni de la concurrence, ni de la saisonnalité ; il faut descendre au niveau City / StoreID et dans le temps pour voir si le retard est général ou concentré.
2. **Réévaluer les promotions avant de les généraliser**
   - **Observation** : 26,5 % des transactions sont en promotion, mais la quantité moyenne (9,92 contre 10,03) et le Revenue moyen (248,7 contre 251,3) ne sont pas supérieurs ; la remise de 5 % retire 2 636 de Revenue (−1,3 %).
   - **Recommandation** : suspendre ou resserrer les promotions peu rentables et passer à des tests A/B par région avant tout déploiement.
   - **Limite / vérification** : analyse observationnelle ; la signification exacte de PromoFlag (distincte de Discount : 90 ventes en promotion sans remise) et la date des campagnes doivent être confirmées.
3. **Fiabiliser les données de référence et de saisie**
   - **Observation** : 88 ventes (11,0 % des lignes, 23 523 soit 11,7 % du Revenue) portent un ProductID 210 absent du référentiel ; Channel est inconnu pour 89 ventes (11,1 %) et PaymentType pour 57 (7,1 %) ; ces incertitudes dépassent l'écart entre les deux premiers modes de paiement (504).
   - **Recommandation** : rendre Channel et PaymentType obligatoires à la saisie, mettre à jour le référentiel produit et contrôler ProductID à l'enregistrement de la vente.
   - **Limite / vérification** : on ignore si le 210 est un vrai produit ou une erreur ; il faut le confirmer auprès du service catalogue, et vérifier la raison des manquants (système, magasin, période) avant de corriger.

Q48

Non, on ne peut pas calculer une marge commerciale réelle avec les colonnes fournies. Dans ce TP, Cost = UnitPrice × Units est le **montant brut de vente** au prix catalogue, avant remise : c'est un prix de vente, pas un coût. Le **coût d'acquisition** est ce que l'entreprise paie pour obtenir le produit (achat au fournisseur ou fabrication, transport, droits de douane). Confondre les deux ferait passer un chiffre d'affaires pour un coût, et la « marge » Revenue – Cost ne serait en réalité que le montant des remises (11,2 % du brut). Il faudrait au minimum :

- le **coût d'achat ou de revient unitaire** par ProductID (coût des marchandises vendues) ;
- les **frais variables** liés à la vente : logistique, livraison, commissions de paiement (Paypal, carte) ;
- les **retours, remboursements et annulations** ;
- le traitement de la **TVA / taxes** (marge calculée hors taxes) ;
- éventuellement les **coûts de promotion** et les coûts fixes par magasin pour une marge nette.

La marge se calculerait alors par (Revenue – coût unitaire × Units – frais variables) ligne par ligne, puis agrégée par produit, catégorie ou région.

09

Efficacité et ouverture Big Data

Questions couvertes : Q49-Q52

Q49

Taille du jeu de test : 200,000 lignes

	Temps (s)	Facteur vs vectorisée
Vectorisée	0.0066	1.0000
Boucle itertuples()	0.2609	39.5043
Boucle iterrows()	19.0622	2886.0708

Interprétation

- Le calcul de Revenue a été effectué sur 200 000 lignes avec trois méthodes : vectorisation, boucle itertuples() et boucle iterrows().
- La vectorisation est la méthode la plus rapide, car elle utilise les opérations optimisées de NumPy sans parcourir les lignes une par une en Python. Les trois méthodes donnent les mêmes résultats.
- Conclusion : il est préférable d'utiliser les opérations vectorisées pour améliorer les performances avec pandas.

Q50

	Ko	Type
Region	46.4	object
OrderTime_Format	44.0	object
City	43.8	object
Zone	42.5	object
Direction	41.4	object
PaymentType	41.2	object
Channel	41.0	object
OrderTime	40.9	object

```
Mémoire avant : 417.0 Ko | après : 85.3 Ko | gain : 79.5%
```

	Avant (Ko)	Après (Ko)
OrderID	6.2	1.6
Region	46.4	1.3
City	43.8	2.7
StoreID	6.2	0.8
Channel	41.0	1.0
CustomerID	6.2	1.6
ProductID	6.2	1.6
Units	6.2	0.8
UnitPrice	6.2	3.1
Discount	6.2	3.1
PaymentType	41.2	1.0
OrderTime_Format	44.0	1.1
Cost	6.2	3.1
Revenue	6.2	3.1
Final_Revenue	6.2	3.1
Zone	42.5	1.0
Direction	41.4	1.0

```
Revenue total : float64 = 200468.26 | optimisé = 200468.25 | écart relatif max par région = 4.2e-08
```

Interprétation

- La conversion des colonnes catégorielles en category, la réduction des types entiers et l'utilisation de float32 diminuent fortement la mémoire utilisée. Le léger écart sur le Revenue provient de la précision limitée de float32.
- Conclusion : l'optimisation des types permet d'économiser de la mémoire tout en conservant des résultats très proches. Pour les calculs comptables exacts, il faut privilégier une précision supérieure.

Q51

Pandas peut rencontrer des difficultés avec plusieurs dizaines de millions de lignes, car il charge les données en mémoire sur une seule machine. Les jointures et les agrégations peuvent nécessiter beaucoup de mémoire supplémentaire.

- Pandas avec traitement par lots (chunksize) : adapté aux données volumineuses lorsque les calculs peuvent être effectués par blocs.
- Dask : adapté au traitement parallèle et aux données dépassant la mémoire disponible sur une machine.
- PySpark : adapté aux traitements distribués sur un cluster et aux très grands volumes de données.

Conclusion

le choix dépend du volume, de la mémoire disponible et du besoin de calcul distribué. Pour un petit jeu de données comme celui du TP, pandas reste suffisant.

Q52

Traitements faciles à distribuer :

- Les transformations ligne par ligne, comme le calcul de Cost, Revenue et Final_Revenue.
- Les filtres et les sélections de données.
- Les agrégations décomposables, comme les sommes, les comptages et les moyennes calculées à partir de sommes et de comptages.

Traitements nécessitant plus d'attention :

- Les jointures, qui peuvent nécessiter un échange de données entre les machines.
- Les doublons, qui doivent être regroupés pour être détectés correctement.
- Les médianes, quantiles et tests statistiques, qui nécessitent des calculs globaux ou des méthodes spécifiques.
- Les données déséquilibrées, notamment les 88 ventes associées au ProductID 210 absent du référentiel.

CONCLUSION

Ce travail d'analyse exploratoire des données (EDA), réalisé avec Python et Pandas, avait pour objectif d'étudier les données de ventes, d'identifier les problèmes de qualité et de dégager des enseignements utiles à la prise de décision.

1. Principaux problèmes de qualité des données
Plusieurs problèmes ont été identifiés :

- Doublons : 16 lignes en double ont été supprimées sur les 816 lignes initiales.
- Valeurs manquantes : les colonnes Channel, PaymentType et OrderTime comportaient des données absentes.
- Références produits incohérentes : 88 ventes (11 % des ventes conservées) possèdent le ProductID 210, absent de la table des produits.
- Limite du calcul des coûts : la variable Cost représente le montant brut de la vente et non le coût réel d'achat du produit.

2. Décisions de préparation les plus importantes
Après nettoyage, le jeu de données contient 800 ventes. Les doublons exacts ont été supprimés. Les valeurs manquantes de Channel (89 lignes) et de PaymentType (57 lignes) ont été remplacées par la catégorie « Inconnu », tandis que les 126 valeurs manquantes de OrderTime ont été conservées. Les variables Cost, Revenue et Final_Revenue ont ensuite été calculées selon les formules définies dans le TP. Enfin, les ventes associées au ProductID 210 ont été conservées afin d'éviter toute perte de données.

CONCLUSION

3. Trois principaux enseignements métier

1. Performance des régions : la région Centre East réalise le chiffre d'affaires le plus élevé, avec 41 471, soit 20,7 % du total. À l'inverse, South West affiche le chiffre d'affaires le plus faible, avec 27 392.

2. Performance des produits : la catégorie Electronics contribue le plus au chiffre d'affaires, avec 30,2 % du total. Elle constitue donc une catégorie importante à suivre dans la stratégie commerciale.

3. Efficacité des promotions : le chiffre d'affaires moyen par transaction est légèrement inférieur avec promotion (248,7) à celui observé sans promotion (251,3). Ces résultats ne permettent donc pas d'affirmer que les promotions augmentent les ventes.

4. Limites et pistes d'amélioration

Cette analyse est principalement descriptive : elle met en évidence des tendances, mais ne permet pas d'établir des relations de cause à effet. De plus, la rentabilité réelle ne peut pas être calculée sans connaître les coûts d'achat et les autres charges. Pour approfondir l'étude, il serait nécessaire de corriger les références produits manquantes, d'améliorer la complétude des données et d'ajouter des informations sur les coûts, les retours, les stocks et l'historique des promotions. Des tests contrôlés permettraient également de mieux mesurer l'efficacité des actions commerciales.

En conclusion, cette analyse fournit une première vision des performances commerciales, mais la fiabilité des décisions dépend de la qualité des données et de contrôles complémentaires.